OpenPod

Local AI is All You Need

วุฒิภัทร วิวัฒน์ชัยกุล
no.3 2/6

นภัสนันท์เลิศปัญญา
no.2 2/6

พิมพ์ขวัญ ใจเจริญสกุลดี
no.10 2/6

วรกันต์ศรีสุทธิพันต์
no.11 2/6

กวินท์ กิจโยธิน
no.15 2/6

วิศิษฐ์ รัตนางกูร
no.10 2/6

ปรียาดาแสนใจยา
no.22 2/6

Abstract

โครงงานนี้มีวัตถุประสงค์เพื่อพัฒนาระบบผู้ช่วยอัจฉริยะที่สามารถทำงานได้ภายในเครื่องโดยไม่ต้องพึ่งพาการประมวลผลผ่านระบบคลาวด์โดยทั่วไปแล้วลำโพงอัจฉริยะหรือผู้ช่วยเสียงมักต้องส่งข้อมูลเสียงของผู้ใช้ไปยังเซิร์ฟเวอร์ภายนอกเพื่อประมวลผล ซึ่งอาจก่อให้เกิดความล่าช้าในการตอบสนองและข้อกังวลด้านความเป็นส่วนตัวของข้อมูล

โครงงาน OpenPod ได้ออกแบบระบบผู้ช่วยอัจฉริยะที่สามารถประมวลผลคำสั่งของผู้ใช้โดยใช้โมเดลภาษา Phi-2 ที่ได้รับการปรับแต่ง (Fine-tuning) เพื่อให้เหมาะสมกับการทำงานในรูปแบบผู้ช่วยอัจฉริยะ ระบบทำงานบนเครื่องคอมพิวเตอร์ที่มีหน่วยประมวลผลกราฟิก (GPU) เพื่อเพิ่มประสิทธิภาพในการประมวลผล และมีส่วนติดต่อผู้ใช้ (Frontend) สำหรับรับคำสั่งและแสดงผลการตอบสนองผลการทดสอบแสดงให้เห็นว่าระบบสามารถรับคำสั่งจากผู้ใช้และประมวลผลได้ภายในเครื่อง เช่น การตอบคำถามหรือการเล่นเพลง โดยไม่จำเป็นต้องใช้บริการปัญญาประดิษฐ์ผ่านอินเทอร์เน็ต โครงงานนี้แสดงให้เห็นถึงความเป็นไปได้ในการพัฒนาผู้ช่วยอัจฉริยะที่ทำงานด้วย Local AI ซึ่งช่วยลดการพึ่งพาระบบคลาวด์และเพิ่มความเป็นส่วนตัวของผู้ใช้

Introduction

เนื้อหาส่วนนี้อธิบายถึงแนวคิดและความสำคัญของการพัฒนาผู้ช่วยอัจฉริยะที่สามารถทำงานได้ภายในเครื่องโดยในปัจจุบันระบบผู้ช่วยเสียง เช่น ลำโพงอัจฉริยะ มักต้องอาศัยการประมวลผลผ่านระบบคลาวด์ ซึ่งอาจทำให้เกิดความล่าช้าในการตอบสนอง รวมถึงข้อกังวลเกี่ยวกับความเป็นส่วนตัวของข้อมูลผู้ใช้ดังนั้นโครงงานนี้จึงนำเสนอ OpenPod ซึ่งเป็นต้นแบบของลำโพงอัจฉริยะที่สามารถทำงานร่วมกับโมเดลภาษาที่รันภายในเครื่อง โดยใช้โมเดลภาษา Phi-2 ที่ผ่านการปรับแต่งให้เหมาะสมกับการทำงานในลักษณะผู้ช่วยอัจฉริยะ ระบบสามารถรับคำสั่งจากผู้ใช้ผ่านส่วนติดต่อผู้ใช้ (Frontend) และประมวลผลคำตอบผ่านโมเดลภาษาที่ทำงานบนเครื่องคอมพิวเตอร์ที่มี GPU

List Of Contents

Abstract&Introduction.....A

List Of Contents .....B

List Of Figuers C

Chapter 1 1

Chapter 2 3

Chapter 3 6

Chapter4 - ผลการทดลอง.....10

บรรณานุกรม 13

ภาคผนวก A 15

List Of Figuers

Figure 1: The Transformer - model architecture.....3

Figure 2: model architecture 6

Figure 2: Flowchart of processing user input. 8

Figure A.1: Design system prompt 15

Figure A.2: preparing presentation 15

Figure A.3: Test Server 15

Figure A.4: Research about frontend 15

Figure A.5: Ai resopnd test 15 16

Figure A.6: sound folder 15 15

List of Tables

Table 1 : อุปกรณ์และเครื่องมือที่ใช้ในการพัฒนา.....7

Table 2:ผลการทดลอง 10

Chapter1 - บทนำ

1.1 ที่มาและความสำคัญของโครงงาน

ในปัจจุบันเทคโนโลยีผู้ช่วยอัจฉริยะ (AI Assistant) และลำโพงอัจฉริยะได้รับความนิยมอย่างแพร่หลาย โดยระบบเหล่านี้สามารถช่วยอำนวยความสะดวกให้กับผู้ใช้ผ่านการสั่งงานด้วยเสียงหรือข้อความ อย่างไรก็ตาม ระบบผู้ช่วยอัจฉริยะส่วนใหญ่จำเป็นต้องอาศัยการประมวลผลผ่านระบบคลาวด์ ซึ่งหมายความว่าข้อมูลของผู้ใช้จะถูกส่งไปยังเซิร์ฟเวอร์ภายนอกเพื่อประมวลผลก่อนที่จะส่งผลลัพธ์กลับมาให้ผู้ใช้ การทำงานในลักษณะดังกล่าวอาจทำให้เกิดความล่าช้าในการตอบสนอง รวมถึงก่อให้เกิดข้อกังวลเกี่ยวกับความเป็นส่วนตัวของข้อมูลด้วยความก้าวหน้าของเทคโนโลยีปัญญาประดิษฐ์ในปัจจุบัน ทำให้สามารถพัฒนาโมเดลภาษาที่มีประสิทธิภาพและสามารถทำงานบนเครื่องคอมพิวเตอร์ส่วนบุคคลได้ โครงงานนี้จึงมีแนวคิดในการพัฒนา OpenPod ซึ่งเป็นต้นแบบของระบบผู้ช่วยอัจฉริยะที่สามารถทำงานได้ภายในเครื่อง (Local AI) โดยไม่จำเป็นต้องพึ่งพาการประมวลผลผ่านระบบคลาวด์ระบบ OpenPod ได้ถูกพัฒนาขึ้นโดยใช้โมเดลภาษา Phi-2 ที่ผ่านการปรับแต่ง (Fine-tuning) เพื่อให้เหมาะสมกับการทำงานในรูปแบบผู้ช่วยอัจฉริยะ โดยระบบสามารถรับคำสั่งจากผู้ใช้ผ่านส่วนติดต่อผู้ใช้ (Frontend) และประมวลผลคำตอบด้วยโมเดลปัญญาประดิษฐ์ที่ทำงานบนเครื่องคอมพิวเตอร์ที่มีหน่วยประมวลผลกราฟิก (GPU)ดังนั้นโครงงานนี้จึงมีความสำคัญในการศึกษาแนวทางการพัฒนาระบบผู้ช่วยอัจฉริยะที่สามารถทำงานได้ภายในเครื่อง ซึ่งช่วยลดการพึ่งพาระบบคลาวด์ เพิ่มความเป็นส่วนตัวของผู้ใช้ และแสดงให้เห็นถึงความเป็นไปได้ในการประยุกต์ใช้เทคโนโลยีปัญญาประดิษฐ์กับฮาร์ดแวร์ระดับผู้ใช้ทั่วไป

1.2 วัตถุประสงค์ของโครงงาน

เพื่อพัฒนาระบบผู้ช่วยอัจฉริยะที่สามารถทำงานได้ภายในเครื่องโดยใช้เทคโนโลยีปัญญาประดิษฐ์

1. เพื่อศึกษาการประยุกต์ใช้โมเดลภาษา Phi-2 ในการพัฒนาระบบผู้ช่วยอัจฉริยะ
2. เพื่อออกแบบและพัฒนาระบบ OpenPod ที่สามารถรับคำสั่งจากผู้ใช้และตอบสนองได้ภายในเครื่อง
3. เพื่อศึกษาความเป็นไปได้ของการพัฒนาระบบผู้ช่วยอัจฉริยะโดยไม่ต้องพึ่งพาการประมวลผลผ่านระบบคลาวด์

1.3 ขอบเขตการศึกษาของโคตรงงาน

โครงงานนี้มุ่งเน้นการพัฒนาต้นแบบของระบบผู้ช่วยอัจฉริยะที่สามารถทำงานภายในเครื่อง โดยมีขอบเขตดังนี้

1.ระบบถูกพัฒนาบนเครื่องคอมพิวเตอร์ส่วนบุคคลที่มีหน่วยประมวลผลกฟิก(GPU)

2.ใช้โมเดลภาษา Phi-2 ที่ผ่านการปรับแต่ง (Fine-tuning) เพื่อใช้เป็นแกนหลักของระบบ

3.ระบบมีส่วนติดต่อผู้ใช้ (Frontend) สำหรับรับคำสั่งและแสดงผลลัพธ์

4.ระบบสามารถประมวลผลคำสั่งพื้นฐานของผู้ใช้ เช่น การตอบคำถามหรือการสั่งเปิดเพลง

5.ระบบทำงานโดยใช้การประมวลผลภายในเครื่อง (Local Processing) โดยไม่จำเป็นต้องใช้บริการปัญญาประดิษฐ์ผ่านคลาวด์

1.4 สมมติฐานของโครงงาน

ระบบผู้ช่วยอัจฉริยะที่พัฒนาโดยใช้โมเดลภาษาและทำงานบนเครื่องคอมพิวเตอร์ที่มีหน่วยประมวลผลกราฟิก (GPU) สามารถทำงานเป็นผู้ช่วยอัจฉริยะพื้นฐานได้โดยไม่จำเป็นต้องพึ่งพาการประมวลผลผ่านระบบคลาวด์

1.5 ตัวแปรที่ใช้ในการศึกษา

ตัวแปรต้น (Independent Variable)

ระบบผู้ช่วยอัจฉริยะที่ใช้การประมวลผลแบบ Local AI

ตัวแปรตาม (Dependent Variable)ความสามารถของระบบในการตอบสนองต่อคำสั่งของผู้ใช้ เช่น การตอบคำถามหรือการทำงานตามคำสั่ง

ตัวแปรควบคุม (Control Variables)

- *ฮาร์ดแวร์ที่ใช้ในการทดสอบ*
- *โมเดลภาษาและชุดข้อมูลที่ใช้ในการปรับแต่ง*
- *สภาพแวดล้อมในการทดสอบระบบ*

Chapter2 - เอกสารและงานวิจัยที่เกี่ยวข้อง

2.1 เทคโนโลยีปัญญาประดิษฐ์และโมเดลภาษา

ปัญญาประดิษฐ์(Artificial Intelligence: AI)เป็นเทคโนโลยีที่ถูกพัฒนาเพื่อให้คอมพิวเตอร์สามารถเรียนรู้วิเคราะห์และประมวลผลข้อมูลได้ในลักษณะที่คล้ายกับการคิดของมนุษย์หนึ่งในสาขาที่สำคัญของปัญญาประดิษฐ์คือการประมวลผลภาษาธรรมชาติ(NaturalLanguageProcessing:NLP) ซึ่งมุ่งเน้นการทำให้คอมพิวเตอร์สามารถเข้าใจและสร้างภาษามนุษย์ได้

ในปัจจุบัน โมเดลภาษา(Language Models) ถูกนำมาใช้ในงานด้านการประมวลผลภาษาธรรมชาติอย่างแพร่หลายโมเดลเหล่านี้สามารถเรียนรู้รูปแบบของภาษาและนำไปใช้ในการตอบคำถามการสรุปข้อความหรือการพัฒนาระบบผู้ช่วยอัจฉริยะโมเดลภาษาสมัยใหม่มักได้รับการฝึกจากชุดข้อมูลขนาดใหญ่ทำให้สามารถสร้างข้อความที่มีความใกล้เคียงกับภาษามนุษย์ได้อย่างมีประสิทธิภาพ

2.2 สถาปัตยกรรม Transformer

หนึ่งในเทคโนโลยีสำคัญที่เป็นพื้นฐานของโมเดลภาษาสมัยใหม่คือสถาปัตยกรรม Transformer ซึ่งถูกนำเสนอครั้งแรกในงานวิจัยเรื่อง Attention Is All You Need โดย Vaswani และคณะ ในปี ค.ศ. 2017สถาปัตยกรรม Transformer มีจุดเด่นคือการใช้กลไกที่เรียกว่า Attention Mechanism ซึ่งช่วยให้โมเดลสามารถพิจารณาความสัมพันธ์ของคำต่าง ๆ ภายในประโยคได้อย่างมีประสิทธิภาพทำให้สามารถเข้าใจบริบทของข้อความได้ดียิ่งขึ้น เทคโนโลยีนี้จึงถูกนำไปใช้เป็นพื้นฐานของโมเดลภาษาขนาดใหญ่จำนวนมากในปัจจุบันด้วยประสิทธิภาพของสถาปัตยกรรมTransformerทำให้เกิดการพัฒนาโมเดลภาษาที่สามารถสร้างข้อความและตอบคำถามได้อย่างแม่นยำซึ่งกลายเป็นพื้นฐานของระบบผู้ช่วยอัจฉริยะและระบบปัญญาประดิษฐ์สมัยใหม่

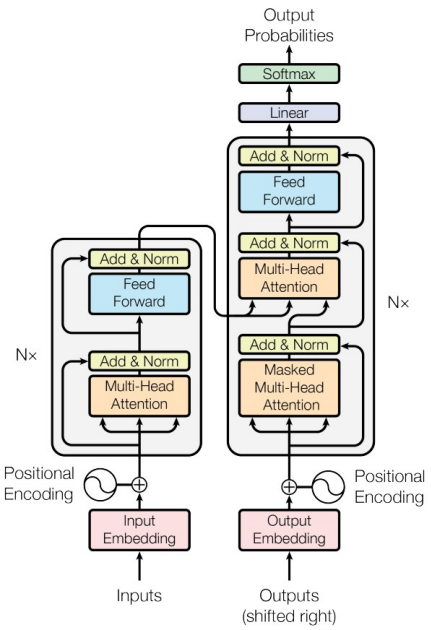

Figure 1: The Transformer - model architecture.

2.3 การประมวลผลด้วยหน่วยประมวลผลกราฟิก (GPU)

การประมวลผลโมเดลปัญญาประดิษฐ์มักต้องใช้ทรัพยากรการคำนวณจำนวนมาก ดยเฉพาะอย่างยิ่งในกรณีของโมเดลภาษาที่มีพารามิเตอร์จำนวนมากหน่วยประมวลผลกราฟิก(Graphics Processing Unit: GPU) จึงถูกนำมาใช้เพื่อเพิ่มประสิทธิภาพในการคำนวณ

GPU มีความสามารถในการประมวลผลแบบขนาน (Parallel Processing) ซึ่งเหมาะสำหรับงานด้านการเรียนรู้ของเครื่องและการประมวลผลข้อมูลขนาดใหญ่เทคโนโลยีCUDAที่พัฒนาโดย NVIDIA ช่วยให้นักพัฒนาสามารถใช้พลังการประมวลผลของ GPU เพื่อเร่งความเร็วในการทำงานของโมเดลปัญญาประดิษฐ์ได้

การใช้GPUในการประมวลผลโมเดลภาษาช่วยให้ระบบสามารถตอบสนองต่อคำสั่งของผู้ใช้ได้รวดเร็วขึ้นและสามารถนำโมเดลปัญญาประดิษฐ์มาใช้งานในระบบที่ต้องการการตอบสนองแบบเรียลไทม์ได้

2.4 โมเดลภาษา Phi-2

Phi-2เป็นโมเดลภาษาขนาดเล็กที่ถูกพัฒนาโดยMicrosoftโดยมีจุดเด่นคือสามารถให้ประสิทธิภาพที่ดีแม้ใช้ทรัพยากรในการประมวลผลไม่มากนักโมเดลประเภทนี้ถูกออกแบบมาเพื่อให้สามารถนำไปใช้งานในระบบที่ต้องการประมวลผลภายในเครื่องเช่นระบบผู้ช่วยอัจฉริยะหรือระบบที่ต้องการทำงานแบบ Local AI

การปรับแต่งโมเดลภาษา (Fine-tuning) เป็นกระบวนการที่นำโมเดลที่ได้รับการฝึกเบื้องต้นแล้วมาปรับให้เหมาะสมกับงานเฉพาะด้าน เช่น การพัฒนาระบบผู้ช่วยอัจฉริยะหรือระบบตอบคำถาม การใช้เทคนิค Fine-tuning ช่วยให้โมเดลสามารถตอบสนองต่อคำสั่งของผู้ใช้ได้อย่างเหมาะสมมากยิ่งขึ้น

2.5 แนวคิดของ Local AI

Local AI เป็นแนวคิดในการพัฒนาระบบปัญญาประดิษฐ์ที่สามารถทำงานภายในอุปกรณ์ของผู้ใช้โดยไม่ต้องพึ่งพาการประมวลผลผ่านระบบคลาวด์ แนวทางนี้มีข้อดีหลายประการ เช่น การลดความล่าช้าในการตอบสนอง การลดการพึ่งพาเครือข่ายอินเทอร์เน็ต และการเพิ่มความเป็นส่วนตัวของข้อมูลผู้ใช้ในปัจจุบันด้วยความก้าวหน้าของฮาร์ดแวร์คอมพิวเตอร์และการพัฒนาโมเดลภาษาที่มีประสิทธิภาพสูง ทำให้สามารถนำระบบปัญญาประดิษฐ์มาประมวลผลภายในเครื่องได้จริง แนวคิดนี้จึงถูกนำมาใช้ในการพัฒนาระบบผู้ช่วยอัจฉริยะที่สามารถทำงานได้โดยไม่ต้องพึ่งพาบริการปัญญาประดิษฐ์จากภายนอกแนวคิดดังกล่าวเป็นพื้นฐานสำคัญในการพัฒนาโครงงาน OpenPod ซึ่งเป็นระบบผู้ช่วยอัจฉริยะที่ใช้โมเดลภาษาทำงานภายในเครื่อง โดยใช้ทรัพยากรของคอมพิวเตอร์ส่วนบุคคลและหน่วยประมวลผลกราฟิกเพื่อประมวลผลคำสั่งของผู้ใช้

Chapter3 - วิธีดำเนินการ

3.1 ภาพรวมของระบบ (System Overview)

โครงงาน OpenPod เป็นระบบผู้ช่วยอัจฉริยะที่สามารถทำงานได้ภายในเครื่องคอมพิวเตอร์โดยไม่ต้องพึ่งพาการประมวลผลผ่านระบบคลาวด์ระบบถูกออกแบบให้สามารถรับคำสั่งจากผู้ใช้ ประมวลผลด้วยโมเดลภาษา และแสดงผลลัพธ์กลับไปยังผู้ใช้ผ่านส่วนติดต่อผู้ใช้

ระบบ OpenPod ประกอบด้วยองค์ประกอบหลัก ได้แก่ ส่วนติดต่อผู้ใช้ (Frontend) โมเดลภาษา (Language Model) และระบบประมวลผลที่ทำงานบนเครื่องคอมพิวเตอร์ที่มีหน่วยประมวลผลกราฟิก (GPU)

3.2 โครงสร้างการทำงานของระบบ

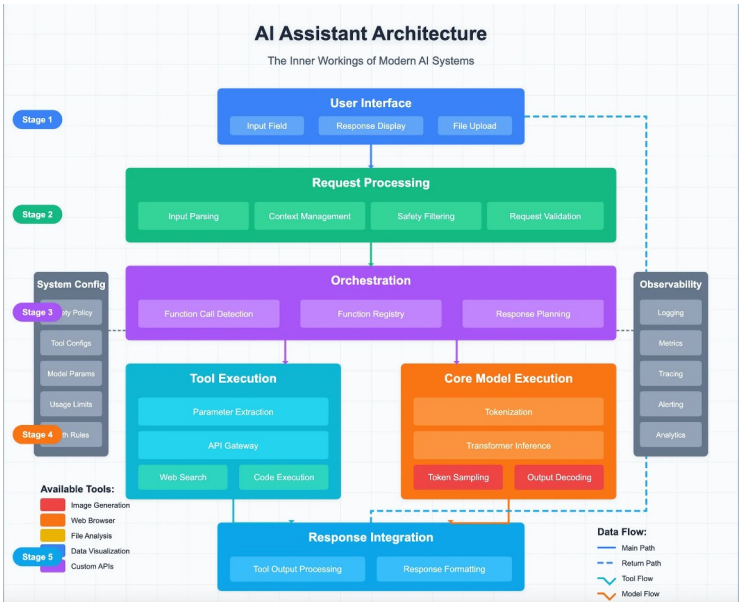

Figure 2: The Transformer - model architectureThe Architecture Behind AI Assistants

ขั้นตอนการทำงานของระบบสามารถอธิบายได้ดังนี้

1. ผู้ใช้ส่งคำสั่งผ่านส่วนติดต่อผู้ใช้
2. ระบบรับคำสั่งและประมวลผลข้อความ
3. ข้อความถูกส่งเข้าสู่โมเดลภาษา Phi-2
4. โมเดลภาษาทำการวิเคราะห์และสร้างคำตอบ
5. ระบบส่งผลลัพธ์กลับไปยังผู้ใช้ หรือดำเนินการตามคำสั่ง เช่น การเปิดเพลง

3.3 อุปกรณ์และเครื่องมือที่ใช้ในการพัฒนา

ในการพัฒนาระบบ OpenPod ได้มีการใช้อุปกรณ์และซอฟต์แวร์ดังแสดงใน

Table 1 : อุปกรณ์และเครื่องมือที่ใช้ในการพัฒนา

ประเภท	รายการ	หน้าที่
ฮาร์ดแวร์	คอมพิวเตอร์	ใช้เป็นเครื่องหลักในการประมวลผล
ฮาร์ดแวร์	GPU	ใช้เร่งความเร็วในการประมวลผลโมเดล
โมเดล AI	Latte(Phi-2 fine tune)	ใช้เป็นโมเดลภาษาสำหรับระบบผู้ช่วย
Framework	Transformers	ใช้สำหรับเรียกใช้งานโมเดลภาษา
ส่วนติดต่อผู้ใช้	Frontend interface	ใช้สำหรับรับคำสั่งจากผู้ใช้
ระบบปฏิบัติการ	Ubuntu server	ใช้ประมวลผลhardware

3.4 ขั้นตอนการพัฒนาระบบ

ขั้นตอนการพัฒนาระบบ OpenPod มีดังนี้

1. ศึกษาเทคโนโลยีโมเดลภาษาและการทำงานของระบบผู้ช่วยอัจฉริยะ
2. เตรียมสภาพแวดล้อมสำหรับการพัฒนา เช่น การติดตั้ง Python และไลบรารีที่จำเป็น
3. เตรียมโมเดลภาษา Phi-2 สำหรับใช้ในการประมวลผล
4. ปรับแต่งโมเดล (Fine-tuning) ด้วยชุดข้อมูลที่เหมาะสม
5. พัฒนาส่วนติดต่อผู้ใช้ (Frontend) สำหรับรับคำสั่งจากผู้ใช้
6. เชื่อมต่อระบบ Frontend กับโมเดลภาษา
7. ทดสอบการทำงานของระบบและปรับปรุงประสิทธิภาพ

3.5 กระบวนการทำงานของระบบ

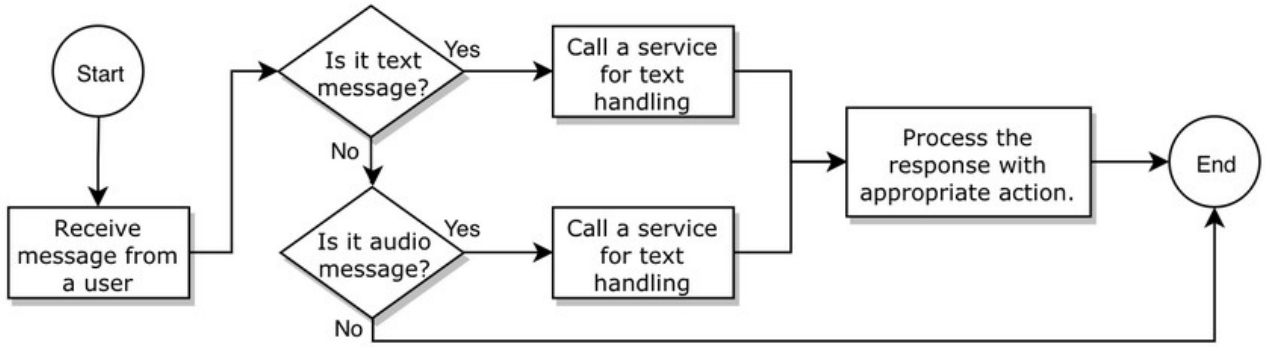

Figure 3: Flowchart of processing user input.

3.6 การทดสอบระบบ

ในการทดสอบระบบ ได้มีการทดสอบการตอบสนองของระบบต่อคำสั่งต่าง ๆ เช่น การตอบคำถาม และการสั่งเปิดเพลง โดยระบบสามารถประมวลผลคำสั่งของผู้ใช้และสร้างผลลัพธ์ได้ภายในเครื่อง โดยไม่ต้องพึ่งพาการประมวลผลผ่านระบบคลาวด์

ผลการทดสอบแสดงให้เห็นว่าระบบ OpenPod สามารถทำงานเป็นผู้ช่วยอัจฉริยะพื้นฐานได้ และสามารถตอบสนองต่อคำสั่งของผู้ใช้ได้อย่างเหมาะสม

Chapter4 - ผลการทดลอง

4.1 การทดสอบการทำงานของระบบ

หลังจากพัฒนาระบบ OpenPod เสร็จสมบูรณ์ ได้ทำการทดสอบการทำงานของระบบโดยการส่งคำสั่งต่าง ๆ ไปยังระบบ เพื่อประเมินความสามารถในการตอบสนองของผู้ช่วยอัจฉริยะที่ทำงานภายในเครื่อง การทดสอบมุ่งเน้นไปที่ความสามารถของระบบในการรับคำสั่งจากผู้ใช้และประมวลผลคำตอบผ่านโมเดลภาษา

ตัวอย่างคำสั่งที่ใช้ในการทดสอบ ได้แก่

- การถามคำถามทั่วไป
- การสั่งเปิดเพลง

  การโต้ตอบกับผู้ช่วยอัจฉริยะ

4.2 ผลการทดลอง

ผลการทดสอบระบบ OpenPod แสดงให้เห็นว่าระบบสามารถรับคำสั่งจากผู้ใช้และประมวลผลได้ภายในเครื่อง โดยไม่จำเป็นต้องเชื่อมต่อกับระบบคลาวด์

คำสั่ง	การตอบสนองของระบบ	ผลลัพธ์
Could you play some music	ระบบเปิดเพลงที่saveไว้	สำเร็จ
คำถามทั่วไป	โมเดลสร้างคำตอบ	สำเร็จ
สนทนากับระบบ	โมเดลตอบกลับด้วยคำตอบจากข้อมูลที่เทรนมาก	สำเร็จ

Table 2:ผลการทดลอง

4.3 การวิเคราะห์ผลการทดลอง

โครงงานนี้ได้พัฒนาระบบผู้ช่วยอัจฉริยะOpenPod ซึ่งสามารถทำงานภายในเครื่องโดยใช้โมเดลภาษาในการประมวลผลคำสั่งของผู้ใช้ ระบบถูกพัฒนาขึ้นบนเครื่องคอมพิวเตอร์ที่มีหน่วยประมวลผลกราฟิก (GPU) และใช้โมเดลภาษา Phi-2 ที่ผ่านการปรับแต่งเพื่อให้เหมาะสมกับการทำงานในลักษณะผู้ช่วยอัจฉริยะ

ผลการทดลองแสดงให้เห็นว่าระบบสามารถรับคำสั่งจากผู้ใช้และประมวลผลคำตอบได้ภายในเครื่อง โดยสามารถทำงานพื้นฐานของผู้ช่วยอัจฉริยะ เช่น การตอบคำถามและการเปิดเพลงได้สำเร็จ

Chapter5 - สรุปผลการทดลอง

5.1 สรุปผลของโครงงาน

โครงงานนี้ได้พัฒนาระบบผู้ช่วยอัจฉริยะ OpenPod ซึ่งสามารถทำงานภายในเครื่องโดยใช้โมเดลภาษาในการประมวลผลคำสั่งของผู้ใช้ ระบบถูกพัฒนาขึ้นบนเครื่องคอมพิวเตอร์ที่มีหน่วยประมวลผลกราฟิก (GPU) และใช้โมเดลภาษา Phi-2 ที่ผ่านการปรับแต่งเพื่อให้เหมาะสมกับการทำงานในลักษณะผู้ช่วยอัจฉริยะ

ผลการทดลองแสดงให้เห็นว่าระบบสามารถรับคำสั่งจากผู้ใช้และประมวลผลคำตอบได้ภายในเครื่อง โดยสามารถทำงานพื้นฐานของผู้ช่วยอัจฉริยะ เช่น การตอบคำถามและการเปิดเพลงได้สำเร็จ

5.2 ข้อดีของระบบ

- สามารถทำงานได้โดยไม่ต้องพึ่งพาระบบคลาวด์
- ช่วยเพิ่มความเป็นส่วนตัวของผู้ใช้
- สามารถปรับแต่งโมเดลให้เหมาะกับการใช้งานเฉพาะได้
- สามารถทำงานบนฮาร์ดแวร์ระดับผู้ใช้ทั่วไปได้

5.3 ข้อจำกัดของระบบ

ประสิทธิภาพของระบบขึ้นอยู่กับฮาร์ดแวร์ที่ใช้

โมเดลภาษาที่มีขนาดเล็กอาจมีข้อจำกัดด้านความแม่นยำ

ระบบยังอยู่ในรูปแบบต้นแบบ (Prototype)

บรรณานุกรม

Gunasekar, S., Zhang, Y., Aneja, J., Mendes, C. C. T., Del Giorno, A., Gopi, S., et al. (2023). Textbooks Are All You Need. Microsoft Research.

https://www.researchgate.net/publication/371729045_Textbooks_Are_All_You_Need

งานวิจัยนี้นำเสนอโมเดลภาษาแบบ Transformer ขนาดเล็กที่สามารถทำงานได้อย่างมีประสิทธิภาพแม้มีจำนวนพารามิเตอร์น้อย โดยใช้ข้อมูลที่มีคุณภาพสูงลักษณะ “textbook quality data” เพื่อเพิ่มประสิทธิภาพในการฝึกโมเดล

Apple Inc. (2024). Prompting an On-Device Foundation Model. Apple Developer Documentation.

https://developer.apple.com/documentation/foundationmodels/prompting-an-on-device-foundation-model

เอกสารนี้อธิบายแนวทางการใช้งานและการออกแบบ prompt สำหรับโมเดลภาษาที่ทำงานภายในอุปกรณ์

NVIDIA Corporation. (2024). CUDA Programming Guide. NVIDIA Developer Documentation.

https://docs.nvidia.com/cuda/

เอกสารนี้อธิบายการใช้งานเทคโนโลยี CUDA สำหรับการประมวลผลแบบขนานบนหน่วยประมวลผลกราฟิก (GPU) ซึ่งช่วยเพิ่มประสิทธิภาพในการคำนวณสำหรับงานด้านปัญญาประดิษฐ์และการเรียนรู้ของเครื่อง

Hugging Face. (2024). Transformers Documentation. Hugging Face.

https://huggingface.co/docs/transformers/index

เอกสารนี้อธิบายการใช้งานไลบรารี Transformers สำหรับการพัฒนาและใช้งานโมเดลภาษาขนาดใหญ่ (LLM) ซึ่งสามารถใช้สำหรับงานด้านการประมวลผลภาษาธรรมชาติ เช่น การสร้างข้อความและการตอบคำถาม

Microsoft. (2023). Phi-2 Language Model. Hugging Face Model Repository. https://huggingface.co/microsoft/phi-2

หน้าโมเดล Phi-2 บน Hugging Face ซึ่งให้รายละเอียดเกี่ยวกับโมเดลภาษา Phi-2 ที่ถูกออกแบบให้มีประสิทธิภาพสูงแม้ใช้ทรัพยากรการประมวลผลไม่มาก เหมาะสำหรับการใช้งานในระบบ AI ที่ทำงานภายในเครื่อง

ภาคผนวก A

Figure A.1: Design system prompt

Figure A.2: preparing presentation

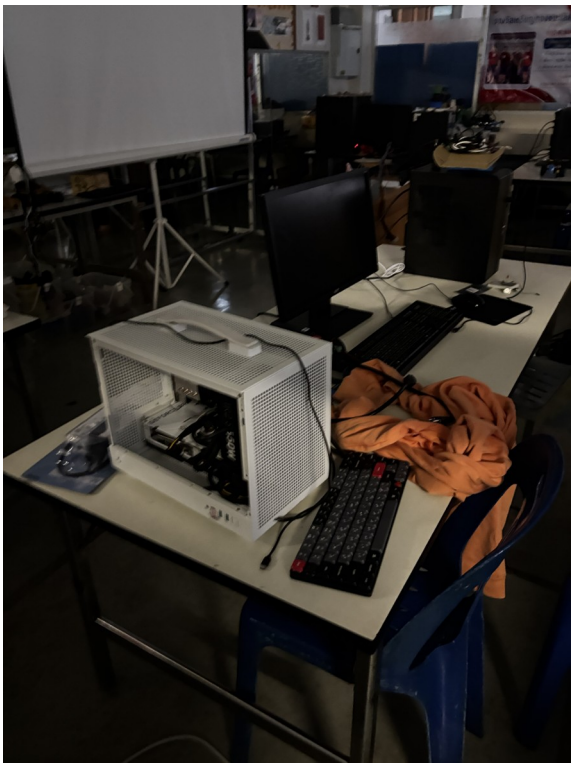

Figure A.3: Test Server

Figure A.4: Research about frontend

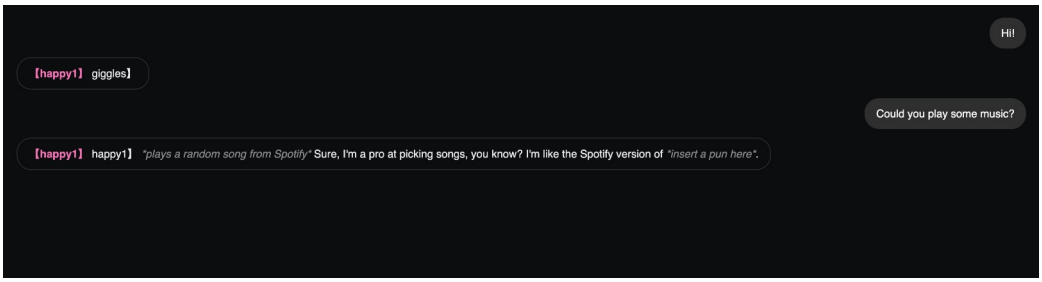

Figure A.5: Ai resopnd test

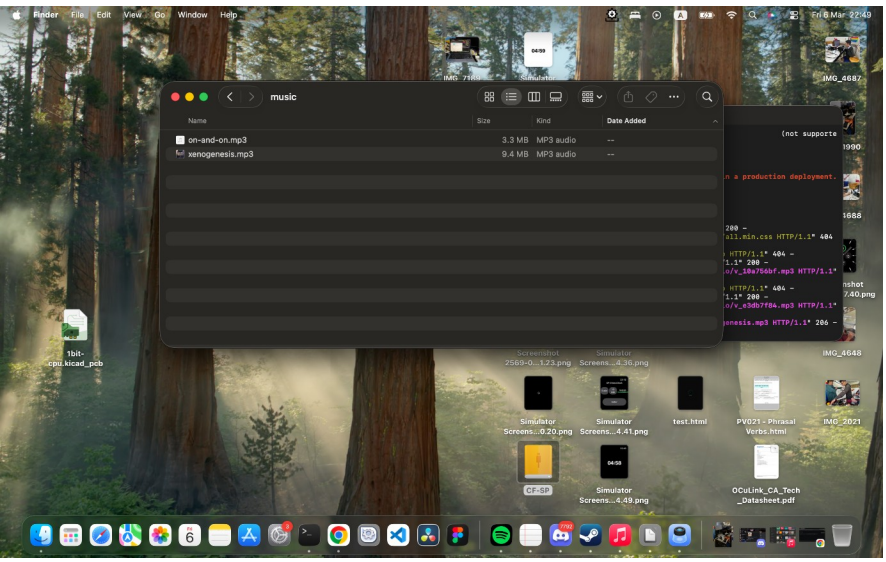

Figure A.6: sound folder